

Trabalho Final da Disciplina de Inteligência Computacional

Eduardo Kurek, Vinicius Kurek

Universidade Tecnológica Federal do Paraná (UTFPR) – Campo Mourão, PR - Brasil
eduardokurek@alunos.utfpr.edu.br, viniciuskurek@alunos.utfpr.edu.br

1. Introdução

Este trabalho tem o propósito de desenvolver um sistema inteligente para identificação de personagens do desenho animado *Simpsons*. Utilizamos a linguagem *python* juntamente com bibliotecas de inteligência artificial como a *scikit-learn* e *torch*.

O *dataset* escolhido contém 5 classes, uma para cada personagem principal. Foi separado em dados de treinamento e validação, a Tabela 1 exibe a quantidade de amostras por classe e tipo do dado.

	BART	HOMER	LISA	MAGGIE	MARGE
TREINAMENTO	78	61	33	30	24
VALIDAÇÃO	35	25	13	12	10

Tabela 1: Distribuição de amostras por classe

O problema é desbalanceado entre as classes, o que torna mais difícil o desenvolvimento de um bom modelo computacional. Nossa ideia é identificar características relevantes das imagens, criar vários modelos diferentes e depois juntá-los a fim de atingir um melhor resultado na identificação dos personagens.

A métrica de classificação escolhida para o trabalho foi a média ponderada do **F1 Score** de cada classe, pois ele funciona bem com problemas desbalanceados.

2. Extração de Características

Para identificar boas características, criamos um modelo base para servir de teste na extração de características. Tal modelo é uma *Random Forest* com alguns parâmetros pré-determinados.

Algumas características foram aplicadas globalmente na imagem, já outras são regionais. Para características regionais, a imagem foi dividida ao meio horizontalmente, a fim de separar torso e pernas do personagem.

Fizemos uma seleção dos parâmetros para a extração de características empiricamente, com vários testes selecionamos os valores que tinham melhores resultados.

2.1. Extração Global

- **Momentos de HU:** Essa característica revela alguns aspectos da imagem relacionados à simetria, medida de dispersão, alongamento, entre outros. Retorna um vetor com 7 características. Mostrou um resultado de **34,39%** de taxa de acerto.
- **Densenet 161:** Rede neural treinada para identificar e extrair características automaticamente da imagem. Retorna um vetor com 2208 características. Mostrou um resultado de **65,40%** de taxa de acerto.

2.2 Extração Regional

- **GLCM:** Avalia a relação entre os pixels, tentando encontrar um padrão de textura. Mostrou um resultado de **36,10%** de taxa de acerto.
- **HOG:** Avalia bordas, ângulos, contornos e silhuetas. Mostrou um resultado de **39,61%** de taxa de acerto.
- **LBP:** Avalia granulação dos pixels, cantos, rugosidade, transições de brilho. Mostrou um resultado de **41,40%** de taxa de acerto.
- **HSV:** Histograma de matiz e intensidade. Mostrou um resultado de **72,79%** de taxa de acerto.

As características que escolhemos para utilizar na fase de treinamento foram o **HSV** e **Densenet 161**, pois demonstraram resultados superiores a 50%. Utilizar características ruins diminui a qualidade do modelo final.

3. Treinamento

Optamos por utilizar várias combinações de parâmetros para 4 modelos diferentes, e obter os 5 melhores modelos. Portanto, utilizamos os classificadores: **KNN**, **MLP**, **RF (Random Forest)**, e **SVM**. Após a execução do **GridSearch** para buscar por melhores parâmetros, salvamos os 5 melhores modelos de cada um dos classificadores escolhidos. As Tabelas 2, 3, 4 e 5 mostram esses resultados respectivamente.

Alguns modelos não são determinísticos, o que pode ocasionar em diferentes resultados para diferentes execuções, nesse caso, temos o **MLP** e o **SVM** (`probability=True`).

Rank	<i>metric</i>	<i>n_neighbors</i>	<i>weights</i>	Score CV
1	<i>manhattan</i>	3	<i>distance</i>	77,86
2	<i>euclidean</i>	5	<i>distance</i>	77,74
3	<i>manhattan</i>	5	<i>distance</i>	77,15
4	<i>manhattan</i>	3	<i>uniform</i>	76,94
5	<i>manhattan</i>	5	<i>uniform</i>	76,64

Tabela 2: Top 5 parâmetros do KNN

Rank	<i>activation</i>	<i>alpha</i>	<i>hidden_layer_sizes</i>	<i>learning_rate</i>	<i>max_iter</i>	<i>solver</i>	Score CV
1	<i>tahn</i>	<i>0,001</i>	<i>200, 100, 50</i>	<i>constant</i>	<i>400</i>	<i>adam</i>	85,00
2	<i>tahn</i>	<i>0,0001</i>	<i>100</i>	<i>constant</i>	<i>400</i>	<i>adam</i>	83,98
3	<i>tahn</i>	<i>0,001</i>	<i>200, 100, 50</i>	<i>constant</i>	<i>200</i>	<i>adam</i>	83,96
4	<i>tahn</i>	<i>0,001</i>	<i>100</i>	<i>constant</i>	<i>200</i>	<i>adam</i>	83,61
5	<i>tahn</i>	<i>0,0001</i>	<i>150, 50</i>	<i>constant</i>	<i>200</i>	<i>sgd</i>	83,36

Tabela 3: Top 5 parâmetros do MLP

Rank	<i>class_weight</i>	<i>max_depth</i>	<i>max_features</i>	<i>n_estimators</i>	<i>random_state</i>	Score CV
1	<i>None</i>	<i>20</i>	<i>0,5</i>	<i>300</i>	<i>42</i>	84,04
2	<i>None</i>	<i>10</i>	<i>0,5</i>	<i>300</i>	<i>42</i>	84,04
3	<i>None</i>	<i>None</i>	<i>0,5</i>	<i>300</i>	<i>42</i>	84,04
4	<i>balanced</i>	<i>None</i>	<i>0,5</i>	<i>300</i>	<i>42</i>	83,83
5	<i>balanced</i>	<i>10</i>	<i>0,5</i>	<i>300</i>	<i>42</i>	83,83

Tabela 4: Top 5 parâmetros do RF

Rank	<i>C</i>	<i>class_weight</i>	<i>gamma</i>	<i>kernel</i>	Score CV
1	<i>10</i>	<i>balanced</i>	<i>auto</i>	<i>rbf</i>	80,81
2	<i>1</i>	<i>balanced</i>	<i>scale</i>	<i>rbf</i>	80,74
3	<i>1</i>	<i>balanced</i>	<i>auto</i>	<i>rbf</i>	80,61
4	<i>10</i>	<i>None</i>	<i>scale</i>	<i>rbf</i>	79,98
5	<i>10</i>	<i>balanced</i>	<i>scale</i>	<i>rbf</i>	79,98

Tabela 5: Top 5 parâmetros do SVM

O melhor classificador encontrado foi o MLP, que teve resultado de **88,52%** de acerto no conjunto de teste. A Figura 1 mostra a sua matriz de confusão.




Figura 1: Matriz de confusão do melhor MLP encontrado

4. Combinação dos Classificadores

Para realizar a combinação dos classificadores, optamos pelo método da média (*VotingClassifier Soft*). Onde é feita a média das probabilidades das classes, e classe com maior probabilidade é selecionada. Devido ao *MLP* e *SVM* não serem determinísticos, obtivemos resultados entre **84,81%** e **87,31%** para diferentes treinamentos do classificador. A Figura 2 contém a matriz de confusão para o modelo com **87,31%** de taxa de acerto.




Figura 2: Matriz de confusão da junção dos classificadores

5. Conclusão

Ao final, obtivemos um melhor resultado com a combinação de diferentes classificadores com o método da média. Sendo uma taxa de acerto de **87,31%** para o melhor treinamento. Já com o melhor MLP individual, obtivemos **85,00%** de taxa de acerto.

O tempo de classificação para o classificador combinado se mostrou rápido, com aproximadamente 3s, tornando-o viável de utilizar.

Portanto, concluímos que a combinação de classificadores foi eficiente para aumentar levemente o percentual de acerto. Mesmo que a diferença seja pequena, é válido utilizar um método mais robusto para a classificação do nosso dataset.